

通过从未知方向观察平面实现灵活的相机标定

课程作业译稿

原论文作者: Zhengyou Zhang

摘要

本文提出一种灵活的新技术, 用于方便地完成相机标定。该方法仅要求相机在少数(至少两个)不同方向下观测一个平面模板。相机或平面模板均可自由移动, 且不需要知道其运动。方法对镜头的径向畸变进行建模。所提出的过程由一个闭式解开始, 随后依据最大似然准则进行非线性细化。我们使用计算机仿真数据和真实数据对所提出的技术进行了测试, 并获得了非常好的结果。与使用昂贵设备(例如两个或三个相互正交的平面)的传统技术相比, 所提出的技术易于使用且具有灵活性。它使三维计算机视觉从实验室环境向现实应用迈进一步。相应的软件可从作者的网页获得。

关键词: 相机标定; 内参数; 镜头畸变; 基于平面的灵活标定; 运动分析; 模型获取

1 动机

相机标定是三维计算机视觉中从二维图像提取度量信息的必要步骤。该领域已经开展了大量工作, 起初来自摄影测量学界(例如见文献[?, ?]), 近来则更多来自计算机视觉领域(例如见文献[?, ?, ?, ?, ?, ?, ?, ?, ?])。粗略地说, 我们可以将这些技术分为两类:

摄影测量标定。标定通过观测一个标定物体来完成, 该物体在三维空间中的几何形状已知且具有很高的精度。标定可以非常高效地完成[?]. 标定物体通常由两个或三个彼此正交的平面组成。有时也使用一个经历精确已知平移的平面[?]. 这些方法需要昂贵的标定装置和复杂的设置。

自标定。这类技术不使用任何标定物体。仅通过在静态场景中移动相机, 场景的刚性通常就可以利用纯图像信息, 从一次相机位移中为相机的内参数提供两个约束[?]. 因此, 如果图像由同一台具有固定内参数的相机拍摄, 那么三幅图像之间的对应关系就足以恢复内参数和外参数, 并据此在相似变换意义下重建三维结构[?, ?]. 尽管这种方法非常灵活, 但目前还不够成熟[?]. 由于需要估计的参数很多, 我们无法始终获得可靠的结果。

还存在其他技术, 例如利用正交方向的消失点进行标定[?, ?], 以及利用纯旋转进行标定[?, ?].

我们当前的研究聚焦于桌面视觉系统(desktop vision system, DVS), 因为使用DVS的潜力很大。相机正变得廉价且无处不在。DVS面向普通大众, 而他们并非计算机视觉专家。典型的计算机用户只会偶尔执行视觉任务, 因此不愿意为昂贵的设备投资。因此, 灵活性、鲁棒性和低成本十分重要。本文所述的相机标定技术正是在这些考虑下开发的。

所提出的技术仅要求相机在少数(至少两个)不同方向下观测一个平面模板。该模板可以用激光打印机打印出来, 并附着在一个“合理的”平面表面上(例如硬质书封面)。相机或平面模板均可用手移动, 且不需要知道其运动。所提出的方法介于摄影测量标定和自标定之间, 这是因为我们使用的是二维度量信息, 而不是三维度量信息或纯粹的隐式信息。我们使用计算机仿真数据和真实数据对所提出的技术进行了测试, 并获得了非常好的结果。与传统方法相比, 所提出的技术灵活得多; 与自标定相比, 它具有相当程度的鲁棒性。我们相信, 这项新技术使三维计算机视觉从实验室环境向现实世界迈进一步。

值得注意的是, Bill Triggs[?]最近提出了一种自标定技术, 它至少需要对平面场景进行五次观测。该技术比我们的方法更加灵活, 但存在初始化困难。Liebowitz和Zisserman[?]描述了一种针对平面透视图像的度量校正技术, 所使用的度量信息包括一个已知角度、两个相等但未知的角度以及一个已知长度比。他们还提到, 只要存在这样的度量校正平面, 就可以对相机的内参数进行标定, 尽管他们没有给出算法或实验结果。

本文的组织结构如下。第2节描述从观测单个平面得到的基本约束。第3节描述标定过程: 我们先给出一个闭式解, 然后进行非线性优化, 同时对镜头径向畸变进行建模。第4节研究所提出的相机标定技术失效的配置; 在实践中, 这些情况很容易避免。第5节给出实验结果, 并使用计算机仿真数据和真实数据验证所提出的技术。附录给出若干细节, 包括估计模型平面与其图像之间单应性的技术。

2 基本方程

我们研究通过观测单个平面得到的相机内参数约束。首先介绍本文使用的记号。

2.1 记号

二维点记为 $\mathbf{m} = [u, v]^T$ ，三维点记为 $\mathbf{M} = [X, Y, Z]^T$ 。我们用波浪号表示在向量末尾添加 1 后得到的增广向量，即 $\tilde{\mathbf{m}} = [u, v, 1]^T$ ，以及 $\tilde{\mathbf{M}} = [X, Y, Z, 1]^T$ 。相机采用通常的针孔模型：三维点 $\mathbf{M}$ 与其图像投影 $\mathbf{m}$ 之间的关系为

$$s\tilde{\mathbf{m}} = \mathbf{A} [\mathbf{R} \quad \mathbf{t}] \tilde{\mathbf{M}}, \quad \mathbf{A} = \begin{bmatrix} \alpha & c & u_0 \\ 0 & \beta & v_0 \\ 0 & 0 & 1 \end{bmatrix}. \quad (1)$$

其中， s 是任意尺度因子； $(\mathbf{R}, \mathbf{t})$ 称为外参数，分别是联系世界坐标系与相机坐标系的旋转和平移； $\mathbf{A}$ 称为相机内参数矩阵； (u_0, v_0) 是主点的坐标； α 和 β 分别是图像 u 轴和 v 轴方向的尺度因子； c 是两个图像轴之间的倾斜参数。

我们使用如下记号缩写： $\mathbf{A}^{-T}$ 表示 $(\mathbf{A}^{-1})^T$ 或 $(\mathbf{A}^T)^{-1}$ 。

2.2 模型平面与其图像之间的单应性

不失一般性，假设模型平面位于世界坐标系的 $Z = 0$ 平面上。将旋转矩阵 $\mathbf{R}$ 的第 i 列记为 $\mathbf{r}_i$ 。由式 (??) 可得

$$s \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \mathbf{A} [\mathbf{r}_1 \quad \mathbf{r}_2 \quad \mathbf{r}_3 \quad \mathbf{t}] \begin{bmatrix} X \\ Y \\ 0 \\ 1 \end{bmatrix} = \mathbf{A} [\mathbf{r}_1 \quad \mathbf{r}_2 \quad \mathbf{t}] \begin{bmatrix} X \\ Y \\ 1 \end{bmatrix}.$$

虽然存在记号上的不严格之处，我们仍用 $\mathbf{M}$ 表示模型平面上的一个点，但此时 $\mathbf{M} = [X, Y]^T$ ，因为 Z 始终等于 0。相应地， $\tilde{\mathbf{M}} = [X, Y, 1]^T$ 。因此，模型点 $\mathbf{M}$ 与其图像点 $\mathbf{m}$ 通过单应性矩阵 $\mathbf{H}$ 联系起来：

$$s\tilde{\mathbf{m}} = \mathbf{H}\tilde{\mathbf{M}}, \quad \mathbf{H} = \mathbf{A} [\mathbf{r}_1 \quad \mathbf{r}_2 \quad \mathbf{t}]. \quad (2)$$

显然， 3×3 矩阵 $\mathbf{H}$ 只定义到一个尺度因子。

2.3 内参数约束

给定模型平面的一幅图像，即可估计一个单应性（见附录 A）。记该单应性为 $\mathbf{H} = [\mathbf{h}_1 \quad \mathbf{h}_2 \quad \mathbf{h}_3]$ 。由式 (??) 可得

$$[\mathbf{h}_1 \quad \mathbf{h}_2 \quad \mathbf{h}_3] = \lambda \mathbf{A} [\mathbf{r}_1 \quad \mathbf{r}_2 \quad \mathbf{t}],$$

其中 λ 是任意标量。利用 $\mathbf{r}_1$ 和 $\mathbf{r}_2$ 相互正交且均为单位向量这一事实，有

$$\mathbf{h}_1^T \mathbf{A}^{-T} \mathbf{A}^{-1} \mathbf{h}_2 = 0. \quad (3)$$

$$\mathbf{h}_1^T \mathbf{A}^{-T} \mathbf{A}^{-1} \mathbf{h}_1 = \mathbf{h}_2^T \mathbf{A}^{-T} \mathbf{A}^{-1} \mathbf{h}_2. \quad (4)$$

这就是给定一个单应性时关于内参数的两个基本约束。由于一个单应性具有 8 个自由度，而外参数有 6 个（旋转 3 个、平移 3 个），因此我们只能得到关于内参数的 2 个约束。

3 相机标定求解

本节详细介绍如何有效求解相机标定问题。首先给出解析解，随后介绍一种基于最大似然准则的非线性优化技术。最后考虑镜头畸变，从而给出解析解和非线性解。

3.1 闭式解

令

$$\begin{aligned} \mathbf{B} &= \mathbf{A}^{-T} \mathbf{A}^{-1} \equiv \begin{bmatrix} B_{11} & B_{12} & B_{13} \\ B_{12} & B_{22} & B_{23} \\ B_{13} & B_{23} & B_{33} \end{bmatrix} \\ &= \begin{bmatrix} \frac{1}{\alpha^2} & -\frac{c}{\alpha^2 \beta} & \frac{cv_0 - u_0 \beta}{\alpha^2 \beta} \\ -\frac{c}{\alpha^2 \beta} & \frac{c^2}{\alpha^2 \beta^2} + \frac{1}{\beta^2} & -\frac{c(cv_0 - u_0 \beta)}{\alpha^2 \beta^2} - \frac{v_0}{\beta^2} \\ \frac{cv_0 - u_0 \beta}{\alpha^2 \beta} & -\frac{c(cv_0 - u_0 \beta)}{\alpha^2 \beta^2} - \frac{v_0}{\beta^2} & \frac{(cv_0 - u_0 \beta)^2}{\alpha^2 \beta^2} + \frac{v_0^2}{\beta^2} + 1 \end{bmatrix}. \end{aligned} \quad (5)$$

注意, $\mathbf{B}$ 是对称矩阵, 可以由一个六维向量定义:

$$\mathbf{b} = [B_{11}, B_{12}, B_{22}, B_{13}, B_{23}, B_{33}]^T. \quad (6)$$

(实际上, 它描述了绝对二次曲线在图像中的表示。)

设 $\mathbf{H}$ 的第 i 个列向量为

$$\mathbf{h}_i = [h_{i1}, h_{i2}, h_{i3}]^T.$$

则有

$$\mathbf{h}_i^T \mathbf{B} \mathbf{h}_j = \mathbf{v}_{ij}^T \mathbf{b}, \quad (7)$$

其中

$$\mathbf{v}_{ij} = [h_{i1}h_{j1}, h_{i1}h_{j2} + h_{i2}h_{j1}, h_{i2}h_{j2}, h_{i3}h_{j1} + h_{i1}h_{j3}, h_{i3}h_{j2} + h_{i2}h_{j3}, h_{i3}h_{j3}]^T.$$

因此, 由给定单应性得到的两个基本约束 (式 (??) 和式 (??)) 可以改写为关于 $\mathbf{b}$ 的两个齐次方程:

$$\begin{bmatrix} \mathbf{v}_{12}^T \\ (\mathbf{v}_{11} - \mathbf{v}_{22})^T \end{bmatrix} \mathbf{b} = \mathbf{0}. \quad (8)$$

如果观测到模型平面的 n 幅图像, 将 n 组如式 (??) 所示的方程叠加, 可得

$$\mathbf{V} \mathbf{b} = \mathbf{0}, \quad (9)$$

其中, $\mathbf{V}$ 是一个 $2n \times 6$ 矩阵。当 $n \geq 3$ 时, 通常可以得到一个除尺度因子外唯一确定的解 $\mathbf{b}$ 。当 $n = 2$ 时, 可以施加无倾斜约束 $c = 0$, 即

$$[0, 1, 0, 0, 0, 0] \mathbf{b} = 0,$$

并将其作为附加方程加入式 (??)。式 (??) 的解是与 $\mathbf{V}^T \mathbf{V}$ 的最小特征值对应的特征向量 (等价地, 是与 $\mathbf{V}$ 的最小奇异值对应的右奇异向量)。

得到 $\mathbf{b}$ 后, 即可计算相机内参数矩阵 $\mathbf{A}$; 具体细节见附录 B。已知 $\mathbf{A}$ 后, 每幅图像的外参数也可直接计算。由式 (??) 有

$$\mathbf{r}_1 = \lambda \mathbf{A}^{-1} \mathbf{h}_1, \quad \mathbf{r}_2 = \lambda \mathbf{A}^{-1} \mathbf{h}_2, \quad \mathbf{r}_3 = \mathbf{r}_1 \times \mathbf{r}_2, \quad \mathbf{t} = \lambda \mathbf{A}^{-1} \mathbf{h}_3,$$

其中

$$\lambda = \frac{1}{\|\mathbf{A}^{-1} \mathbf{h}_1\|} = \frac{1}{\|\mathbf{A}^{-1} \mathbf{h}_2\|}.$$

当然, 由于数据中存在噪声, 按此方式计算得到的矩阵 $\mathbf{R} = [\mathbf{r}_1, \mathbf{r}_2, \mathbf{r}_3]$ 通常不满足旋转矩阵的性质。附录 C 描述了如何从一般的 3×3 矩阵估计最佳旋转矩阵的方法。

3.2 最大似然估计

上述解是通过最小化一个不具有物理意义的代数距离得到的。可以利用最大似然估计对其进行细化。

设给定模型平面的 n 幅图像, 模型平面上有 m 个点。假设图像点受到独立同分布噪声的干扰。最大似然估计可以通过最小化下述泛函得到:

$$\sum_{i=1}^n \sum_{j=1}^m \|m_{ij} - \hat{m}(\mathbf{A}, \mathbf{R}_i, \mathbf{t}_i, M_j)\|^2. \quad (10)$$

其中, $\hat{m}(\mathbf{A}, \mathbf{R}_i, \mathbf{t}_i, M_j)$ 是根据式 (??) 将点 M_j 投影到第 i 幅图像上的结果。旋转 $\mathbf{R}$ 由一个三参数向量 (记为 $\mathbf{r}$) 参数化, 该向量与旋转轴平行, 其模长等于旋转角。 $\mathbf{R}$ 与 $\mathbf{r}$ 通过 Rodrigues 公式相关联 [?]. 最小化式 (??) 是一个非线性最小化问题, 使用 Minpack 中实现的 Levenberg-Marquardt 算法求解 [?]. 该算法需要 $\mathbf{A}$ 以及 $\{\mathbf{R}_i, \mathbf{t}_i \mid i = 1..n\}$ 的初始估计, 这些初始值可以通过上一小节所述的技术得到。

3.3 处理径向畸变

到目前为止, 我们还没有考虑相机的镜头畸变。然而, 桌面相机通常表现出显著的镜头畸变, 尤其是径向畸变。本节仅考虑径向畸变的前两项。关于更复杂的模型, 读者可参阅文献 [?, ?, ?, ?]。根据已有文献的报告 [?, ?, ?], 畸变函数很可能完全由径向分量主导, 尤其由第一项主导。已有研究还发现, 更复杂的建模不仅没有帮助 (与传感器量化相比其影响可以忽略), 还会导致数值不稳定 [?, ?]。

令 (u, v) 表示理想的 (不可观测的、无畸变的) 像素图像坐标, $(\check{u}, \check{v})$ 表示与之对应的实际观测图像坐标。类似地, (x, y) 和 $(\check{x}, \check{y})$ 分别表示理想的 (无畸变的) 和实际的 (有畸变的) 归一化图像坐标。有如下关系 [?, ?]

$$\begin{aligned} \check{x} &= x + x [k_1(x^2 + y^2) + k_2(x^2 + y^2)^2], \\ \check{y} &= y + y [k_1(x^2 + y^2) + k_2(x^2 + y^2)^2], \end{aligned}$$

其中, k_1 和 k_2 是径向畸变系数。径向畸变的中心与主点相同。由

$$\check{u} = u_0 + \alpha\check{x} + c\check{y}, \quad \check{v} = v_0 + \beta\check{y}$$

可得

$$\check{u} = u + (u - u_0) [k_1(x^2 + y^2) + k_2(x^2 + y^2)^2], \quad (11)$$

$$\check{v} = v + (v - v_0) [k_1(x^2 + y^2) + k_2(x^2 + y^2)^2]. \quad (12)$$

通过交替估计径向畸变。 由于径向畸变预计较小, 因此可以预期, 使用第 ?? 节所述技术、简单地忽略畸变, 也能够较为合理地估计其他五个内参数。一种策略是在估计其他参数之后再估计 k_1 和 k_2 。由式 (??) 和式 (??), 每幅图像中的每个点均可得到两个方程:

$$\begin{bmatrix} (u - u_0)(x^2 + y^2) & (u - u_0)(x^2 + y^2)^2 \\ (v - v_0)(x^2 + y^2) & (v - v_0)(x^2 + y^2)^2 \end{bmatrix} \begin{bmatrix} k_1 \\ k_2 \end{bmatrix} = \begin{bmatrix} \check{u} - u \\ \check{v} - v \end{bmatrix}.$$

给定 n 幅图像中的 m 个点, 将所有方程叠加后总共得到 $2mn$ 个方程, 或写成矩阵形式 $\mathbf{D}k = d$, 其中 $k = [k_1, k_2]^T$ 。线性最小二乘解为

$$k = (\mathbf{D}^T \mathbf{D})^{-1} \mathbf{D}^T d. \quad (13)$$

得到 k_1 和 k_2 后, 可以通过求解式 (??) 来细化其他参数, 只需将其中的 $\hat{m}(\mathbf{A}, \mathbf{R}_i, \mathbf{t}_i, M_j)$ 替换为式 (??) 和式 (??) 所描述的投影。可以交替执行这两个过程, 直到收敛。

完整的最大似然估计。 通过实验发现, 上述交替技术的收敛速度较慢。因此, 对式 (??) 的自然扩展是通过最小化下述泛函来估计完整的参数集:

$$\sum_{i=1}^n \sum_{j=1}^m \|m_{ij} - \check{m}(\mathbf{A}, k_1, k_2, \mathbf{R}_i, \mathbf{t}_i, M_j)\|^2. \quad (14)$$

其中, $\check{m}(\mathbf{A}, k_1, k_2, \mathbf{R}_i, \mathbf{t}_i, M_j)$ 是根据式 (??) 将点 M_j 投影到第 i 幅图像上、再依据式 (??) 和式 (??) 施加畸变后的结果。这是一个非线性最小化问题, 使用 Minpack 中实现的 Levenberg-Marquardt 算法求解 [?]. 旋转仍然像第 ?? 节中一样由三维向量 $\mathbf{r}$ 参数化。 $\mathbf{A}$ 以及 $\{\mathbf{R}_i, \mathbf{t}_i \mid i = 1..n\}$ 的初始估计可以使用第 ?? 节或第 ?? 节所述技术获得。 k_1 和 k_2 的初始估计可以使用上一段所述技术获得, 也可以直接将其设为 0。

3.4 总结

推荐的相机标定流程如下:

1. 打印一个模板, 并将其粘贴到平面表面上;
2. 通过移动平面或相机, 在不同方向下拍摄几幅模型平面的图像;
3. 检测图像中的特征点;
4. 使用第 ?? 节所述的闭式解, 估计五个内参数和全部外参数;
5. 求解线性最小二乘问题 (??), 估计径向畸变系数;
6. 通过最小化式 (??) 对全部参数进行细化。

4 退化配置

本节研究这样一些配置: 在这些配置中, 增加图像并不会为相机内参数提供更多约束。由于式 (??) 和式 (??) 源自旋转矩阵的性质, 如果 $\mathbf{R}_2$ 不独立于 $\mathbf{R}_1$, 则第 2 幅图像不会提供额外约束。特别地, 如果一个平面仅发生平移, 则 $\mathbf{R}_2 = \mathbf{R}_1$, 此时第 2 幅图像对相机标定没有帮助。下面考虑一种更复杂的配置。

命题 1. 如果模型平面在第二个位置与其第一个位置平行, 则第二个单应性不会提供额外约束。

证明因篇幅所限略去, 可参见我们的技术报告 [?]. 在实践中, 退化配置非常容易避免: 只需改变模型平面在相邻两次拍摄之间的方向即可。

5 实验结果

所提出的算法在计算机模拟数据和真实数据上都进行了测试。闭式解涉及对一个小型 $2n \times 6$ 矩阵进行奇异值分解, 其中 n 为图像数量。Levenberg-Marquardt 算法中的非线性细化经过 3 至 5 次迭代即可收敛。

5.1 计算机模拟

模拟相机的参数为 $\alpha = 1250$ 、 $\beta = 900$ 、 $c = 1.09083$ （等价于 89.95° ）、 $u_0 = 255$ 和 $v_0 = 255$ 。图像分辨率为 512×512 。模型平面是一个包含 $10 \times 14 = 140$ 个角点的棋盘格（因此 v 方向的数据通常多于 u 方向），模板尺寸为 $18\text{cm} \times 25\text{cm}$ 。平面的姿态用三维向量 $\mathbf{r}$ 表示： $\mathbf{r}$ 与旋转轴平行，其模等于旋转角。平面的位置用三维向量 $\mathbf{t}$ 表示，单位为厘米。

噪声水平的影响 在该实验中，使用三个平面，其姿态和位置分别为

$$\begin{aligned} \mathbf{r}_1 &= [20^\circ, 0, 0]^\top, & \mathbf{t}_1 &= [-9, -12.5, 500]^\top, \\ \mathbf{r}_2 &= [0, 20^\circ, 0]^\top, & \mathbf{t}_2 &= [-9, -12.5, 510]^\top, \\ \mathbf{r}_3 &= \frac{1}{\sqrt{5}}[-30^\circ, -30^\circ, -15^\circ]^\top, & \mathbf{t}_3 &= [-10.5, -12.5, 525]^\top. \end{aligned}$$

在投影得到的图像点上加入均值为 0、标准差为 σ 的高斯噪声。将估计得到的相机参数与真实值进行比较：对 α 和 β 测量相对误差，对 u_0 和 v_0 测量绝对误差。噪声水平从 0.1 像素变化到 1.5 像素；对每个噪声水平进行 100 次相互独立的试验，图中结果取平均值。




图 1：图像点噪声水平对应的误差。

如图??所示，误差随噪声水平近似线性增加。参数 c 的误差未在图中给出，但具有相同的变化规律。当 $\sigma = 0.5$ （该噪声水平高于实际标定中的通常噪声）时， α 和 β 的误差小于 0.3%，而 u_0 和 v_0 的误差约为 1 像素。 u_0 的误差大于 v_0 的误差，主要原因是 u 方向的数据少于 v 方向的数据。

模型平面图像数量的影响 该实验考察图像数量（更准确地说，是模型平面图像的数量）对性能的影响。前 3 幅图像中模型平面的姿态和位置与上一小节相同。从第 4 幅图像开始，首先从均匀球面上随机选择旋转轴，然后施加 30° 的旋转角。图像数量从 2 幅变化到 16 幅。对于每一个图像数量，进行 100 次相互独立的试验；除前 3 幅图像外，平面姿态相互独立，噪声也相互独立，噪声均值为 0，标准差为 0.5 像素。图??给出了平均结果。

随着图像数量增加，误差逐渐减小；从 2 幅图像增加到 3 幅图像时，误差下降尤其明显。

模型平面姿态的影响 该实验考察模型平面相对于图像平面的姿态对性能的影响。实验使用 3 幅图像。平面初始时与图像平面平行，然后从均匀球面上随机选择旋转轴，并绕该轴旋转 θ 角。投影图像点上加入均值为 0、标准差为 0.5 像素的高斯噪声。重复这一过程 100 次并计算平均误差， θ 从 5° 变化到 75° ，结果如图??所示。

当 $\theta = 5^\circ$ 时，由于各平面几乎相互平行，40% 的试验失败（退化配置）；图??中的结果排除了这些失败试验。最佳性能似乎在约 45° 的角度处取得。需要注意的是，在实际应用中，随着角度增大，透视缩短会使角点检测变得不够精确，但本实验没有考虑这一因素。

5.2 真实数据

所提出的技术目前已在作者所在的视觉组和图形学组中常规使用。下面给出一个实例的结果。

待标定相机是一台配备 6mm 镜头的商用 PULNiX CCD 相机，图像分辨率为 640×480 。模型平面包含 8×8 个方格，因此共有 256 个角点；模板尺寸为 $17\text{cm} \times 17\text{cm}$ 。拍摄了平面处于不同姿态下的 5 幅图像，如图??所示。可以观察到图像中存在明显的镜头畸变。角点通过拟合每个方格的直线，并取直线交点来检测。




图 2: 模型平面图像数量对应的误差。




图 3: 模型平面相对于图像平面的角度对应的误差。




图 4: 模型平面的五幅图像及提取的角点；角点以十字标记表示，但标记过小，难以直接观察。

将标定算法分别应用于前 2、3、4 幅图像以及全部 5 幅图像，结果见表??。对于每种配置，表中给出三列结果：第一列（初始值）是闭式解的估计结果，第二列（最终值）是最大似然估计（MLE），第三列（ σ ）是估计的标准差，用于表示最终结果的不确定性。可以看出，闭式解是合理的；无论使用 2、3、4 还是 5 幅图像，最终估计值都非常一致。还可以看到，最终估计结果的不确定性随图像数量增加而减小。表??的最后一行 RMS 表示检测图像点与投影图像点之间距离的均方根，单位为像素；最大似然估计显著改善了这一指标。

表 1: 使用 2 至 5 幅图像的真实数据标定结果。

图像数 参数	2 幅图像			3 幅图像			4 幅图像			5 幅图像		
	初始	最终	σ	初始	最终	σ	初始	最终	σ	初始	最终	σ
α	825.59	830.47	4.74	917.65	830.80	2.06	876.62	831.81	1.56	877.16	832.50	1.41
β	825.26	830.24	4.85	920.53	830.69	2.10	876.22	831.82	1.55	876.80	832.53	1.38
c	0	0	0	2.2956	0.1676	0.109	0.0658	0.2867	0.095	0.1752	0.2045	0.078
u_0	295.79	307.03	1.37	277.09	305.77	1.45	301.31	304.53	0.86	301.04	303.96	0.71
v_0	217.69	206.55	0.93	223.36	206.42	1.00	220.06	206.79	0.78	220.41	206.56	0.66
k_1	0.161	-0.227	0.006	0.128	-0.229	0.006	0.145	-0.229	0.005	0.136	-0.228	0.003
k_2	-1.955	0.194	0.032	-1.986	0.196	0.034	-2.089	0.195	0.028	-2.042	0.190	0.025
RMS	0.761	0.295		0.987	0.393		0.927	0.361		0.881	0.335	

表??的 RMS 行原表仅列出初始值和最终值，没有给出 σ ，因此对应单元格留空。

表??中 k_1 和 k_2 的闭式解与最大似然估计之间存在不一致，细心的读者可能会注意到这一点。原因在于，闭式解在假设不存在畸变的条件下估计相机内参数，预测得到的外侧点比检测点更靠近图像中心。随后进行的畸变估计试图使外侧点向外扩展并增大尺度，以减小误差；然而，这一过程中得到的畸变形状（正 k_1 ，称为枕形畸变）并不对应真实畸变（负 k_1 ，称为桶形畸变）。非线性细化（MLE）最终恢复了正确的畸变形状。估计得到的畸变参数可以用于校正原始图像中的畸变。




图 5: 径向畸变校正后的第一幅和第二幅图像。

图??显示了经过畸变校正的前两幅图像，应将其与图??中的前两幅图像进行比较。可以清楚地看到，原始图像中弯曲的图案被拉直了。

标定结果的变化 上文表??给出了使用 2 至 5 幅图像时的标定结果；可以发现这些结果彼此非常一致。为进一步考察所提出算法的稳定性，将可用的 5 幅图像中所有由 4 幅图像组成的组合都用于标定，结果见表??。例如，表中的第三列（1235）表示使用第 1、2、3 和 5 幅图像组成的组合。最后两列分别给出了 5 组结果的均值和样本标准差。所有参数的样本标准差都很小，这说明所提出的算法具有很好的稳定性。

倾斜参数 c 与 0 的差异并不显著，因为其变异系数 $0.086/0.1401 = 0.6$ 较大。事实上， $c = 0.1401$ 、 $\alpha = 832.85$ 对应于图像两轴夹角为 89.99° ，这与 90° 非常接近。我们还计算了每个四幅图像组合的纵横比 α/β 。纵横比的均值为 0.99995，样本标准差为 0.00012，因此它非常接近 1，即像素近似为正方形。

在基于图像的建模中的应用 使用同一台已完成标定的相机拍摄了一个茶叶罐的两幅图像（见图??）。图像中主要可见茶叶罐的两个侧面。我们在每个侧面上手工选取了 8 个点匹配，并将此前开发的运动恢复结构软件应用

表 2: 所有四幅图像组合之间的标定结果变化。

图像组合/参数	(1234)	(1235)	(1245)	(1345)	(2345)	均值	偏差
α	831.81	832.09	837.53	829.69	833.14	832.85	2.90
β	831.82	832.10	837.53	829.91	833.11	832.90	2.84
c	0.2867	0.1069	0.0611	0.1363	0.1096	0.1401	0.086
u_0	304.53	304.32	304.57	303.95	303.53	304.18	0.44
v_0	206.79	206.23	207.30	207.16	206.33	206.76	0.48
k_1	-0.229	-0.228	-0.230	-0.227	-0.229	-0.229	0.001
k_2	0.195	0.191	0.193	0.179	0.190	0.190	0.006
RMS	0.361	0.357	0.262	0.358	0.334	0.334	0.04

于这 16 个点匹配，以建立茶叶罐的部分模型。重建模型采用 VRML 格式，图??给出了三个渲染视图。每个侧面上的重建点确实共面；计算得到的两个重建平面之间的夹角为 94.7°。虽然没有真实值可供比较，但茶叶罐的两个侧面实际上确实几乎相互正交。




图 6: 茶叶罐的两幅图像。




图 7: 重建茶叶罐的三个渲染视图。

包括全部真实数据、结果和软件在内的资料可从以下网页获得：

<http://research.microsoft.com/~zhang/Calib/>。

6 结论

本文提出了一种新的灵活技术，可以方便地完成相机标定。该技术只要求相机从少数几个（至少两个）不同方向观察一个平面模板。相机或平面模板均可移动，且不需要知道其运动。方法对径向镜头畸变进行了建模。所提出的流程由闭式解和随后基于最大似然准则的非线性细化组成。

我们使用计算机模拟和真实数据对所提出的技术进行了测试，并取得了非常好的结果。与需要使用两个或三个相互正交平面等昂贵设备的经典技术相比，所提出的技术具有显著的灵活性优势。

致谢

感谢 Brian Guenter 提供角点提取软件并进行了多次讨论，感谢 Bill Triggs 提供富有启发性的评论。感谢 Andrew Zisserman 使我注意到他的 CVPR98 工作 [?]; 该工作使用了相同的约束，但形式不同。感谢 Bill Triggs 和 Gideon Stein 建议开展关于模型不精确性的实验，该实验见技术报告 [?]。Anandan 和 Charles Loop 审阅了早期版本的英文。

A 模型平面与图像之间单应性的估计

估计模型平面与其图像之间单应性的方法有很多。这里给出一种基于最大似然准则的技术。设 $\mathbf{M}_i$ 和 $\mathbf{m}_i$ 分别为模型点和图像点。理想情况下，它们应满足式 (??)。但在实际中，由于提取出的图像点含有噪声，这一关系并不严格成立。假设 $\mathbf{m}_i$ 受到均值为 0、协方差矩阵为 $\Lambda_{\mathbf{m}_i}$ 的高斯噪声干扰，则单应性矩阵 $\mathbf{H}$ 的最大似然估计通过最小化下列泛函得到：

$$\sum_i (\mathbf{m}_i - \hat{\mathbf{m}}_i)^\top \Lambda_{\mathbf{m}_i}^{-1} (\mathbf{m}_i - \hat{\mathbf{m}}_i),$$

其中

$$\hat{\mathbf{m}}_i = \frac{1}{\tilde{\mathbf{h}}_3^\top \tilde{\mathbf{M}}_i} \begin{bmatrix} \tilde{\mathbf{h}}_1^\top \tilde{\mathbf{M}}_i \\ \tilde{\mathbf{h}}_2^\top \tilde{\mathbf{M}}_i \end{bmatrix},$$

其中 $\tilde{\mathbf{h}}_i$ 是 $\mathbf{H}$ 的第 i 行。

在实践中，我们简单地对所有 i 假设 $\Lambda_{\mathbf{m}_i} = \sigma^2 \mathbf{I}$ 。如果各点是按照相同的过程彼此独立地提取的，这一假设是合理的。在这种情况下，上述问题变为非线性最小二乘问题，即

$$\min_{\mathbf{H}} \sum_i \|\mathbf{m}_i - \hat{\mathbf{m}}_i\|^2.$$

非线性最小化采用 Minpack [?] 中实现的 Levenberg-Marquardt 算法完成。这需要一个初始猜测值，而该初始值可以如下获得。

令

$$\mathbf{x} = \begin{bmatrix} \tilde{\mathbf{h}}_1^\top & \tilde{\mathbf{h}}_2^\top & \tilde{\mathbf{h}}_3^\top \end{bmatrix}^\top.$$

则式 (??) 可以改写为

$$\begin{bmatrix} \tilde{\mathbf{M}}^\top & \mathbf{0}^\top & -u\tilde{\mathbf{M}}^\top \\ \mathbf{0}^\top & \tilde{\mathbf{M}}^\top & -v\tilde{\mathbf{M}}^\top \end{bmatrix} \mathbf{x} = \mathbf{0}.$$

当给定 n 个点时，就有 n 个上述方程，它们可以写成矩阵方程 $\mathbf{L}\mathbf{x} = \mathbf{0}$ ，其中 $\mathbf{L}$ 是一个 $2n \times 9$ 矩阵。由于 $\mathbf{x}$ 只定义到一个尺度因子，众所周知，其解是与最小奇异值对应的 $\mathbf{L}$ 的右奇异向量（或者等价地，是与最小特征值对应的 $\mathbf{L}^\top \mathbf{L}$ 的特征向量）。

在 $\mathbf{L}$ 中，有些元素恒为 1，有些以像素为单位，有些以世界坐标为单位，还有一些是二者的乘积。这使得 $\mathbf{L}$ 在数值上条件很差。在执行上述过程之前进行简单的数据归一化（例如采用文献 [?] 提出的方法），可以获得好得多的结果。

B 从矩阵 B 提取内参数

如第 3.1 节所述，矩阵 $\mathbf{B}$ 的估计只确定到一个尺度因子，即

$$\mathbf{B} = \lambda \mathbf{A}^{-\top} \mathbf{A}^{-1},$$

其中 λ 是任意尺度因子。由矩阵 $\mathbf{B}$ 唯一地提取内参数并不困难。

$$\begin{aligned} v_0 &= \frac{B_{12}B_{13} - B_{11}B_{23}}{B_{11}B_{22} - B_{12}^2}, \\ \lambda &= B_{33} - \frac{B_{13}^2 + v_0(B_{12}B_{13} - B_{11}B_{23})}{B_{11}}, \\ \alpha &= \sqrt{\frac{\lambda}{B_{11}}}, \\ \beta &= \sqrt{\frac{\lambda B_{11}}{B_{11}B_{22} - B_{12}^2}}, \\ c &= -\frac{B_{12}\alpha^2\beta}{\lambda}, \\ u_0 &= \frac{cv_0}{\alpha} - \frac{B_{13}\alpha^2}{\lambda}. \end{aligned}$$

C 用旋转矩阵逼近 3×3 矩阵

本节所讨论的问题是求解一个最佳旋转矩阵 $\mathbf{R}$ ，以逼近给定的 3×3 矩阵 $\mathbf{Q}$ 。这里的“最佳”是指使差值 $\mathbf{R} - \mathbf{Q}$ 的 Frobenius 范数最小。相关解法可参见我们的技术报告 [?]